

SAÉ 3-01-EMS Recueil et analyse de données par échantillonnage ou plan d'expérience

TD/TP - Package sampling

B. Alglave, L. Bellanger, C. Friguet

Le package R `sampling` est disponible sur <http://cran.r-project.org/> (site de développement de R). Il a été développé par Y. Tillé et A. Matei (Univ. Neuchâtel, Suisse). Le package permet de tirer des échantillons dans une population donnée, selon plusieurs méthodes d'échantillonnages et propose des estimateurs du total ou de la moyenne d'une variable d'intérêt.

Après avoir installé le package pour la 1ère utilisation (`packages>install le(s) package(s)>choix du site miroir (France : Lyon par ex.)>sampling`), il faut le charger dans R :

```
library(sampling)
```

Il est vivement conseillé (obligatoire ?!) d'écrire les commandes au préalable dans un script R, et de documenter le code (rappel : une ligne de commentaire commence par le signe #). D'autre part, l'utilisation de Rstudio est également conseillée (obligatoire ?!).

Dans ce TP, nous allons mettre en oeuvre les différentes méthodes vues en cours avec les fonctions de ce package.

1 Les données

On va étudier des données de la population Bretonne récupérées sur le site web de l'INSEE et sur data.gouv.fr, et regroupées dans le fichier `popBZH.csv`.

On dispose pour l'ensemble des communes de la région des informations suivantes:

- "Region-libelle" : nom de la région (Bretagne pour tous les individus)
- "DEPARTEMENT-libelle" : nom du département
- "COG" : Code Officiel Géographique (identifiant unique de chaque commune)
- "COMMUNE-nom" : nom de la commune
- "SURFACE-ha" : surface du territoire, en hectare
- "pop-09" : population en 2009
- "pop-12" : population en 2012
- "nb-LogementVacants" : nombre de logement vacants
- "nb-LogementsTotal" : nombre total de logements
- "ClassementLoiLittoral" : classement par la Loi Littoral (oui/non)

- "nb-Residences2d" : nombre de résidences secondaires

Plus particulièrement dans ce TP, on s'intéresse à l'estimation du nombre (total) d'habitants, ainsi qu'au nombre (total) de résidences secondaires dans la région Bretagne, en 2012.

- Importer les données dans R, stocker les données dans un objet appelé `popBZH`
- A quoi correspond une ligne du tableau? Quelles sont les variables à disposition?
- Quelle est la population? Sa taille?
- Réaliser un rapide résumé des données.

2 Sondage Aléatoire Simple sans remise (à probabilités égales)

2.1 Tirage d'un échantillon dans la population

Tirage Aléatoire Simple, à probabilités égales, sans remise Il y a C_N^n façons possibles de tirer n individus dans une population de N individus. La fonction `writesample` du package `sampling` renvoie tous les échantillons possibles, à savoir une matrice de dimension $C_N^n \times N$ avec un 1 si l'individu i ($i \in [1; N]$) à été tiré et 0 sinon.

Attention: sur des populations d'effectif important, on peut rapidement être confronté à des problèmes de stockage.

En guise d'illustration, par exemple, pour tirer un échantillon de $n = 4$ individus dans une population de $N = 10$ individus, il y a $C_{10}^4 = 210$ façons de le faire:

```
# exemple des échantillons de taille n parmi une population de taille N
n<-4
N<-10
w<-writesample(n=n,N=N)
dim(w)
```

```
## [1] 210 10
```

```
w[1:10,]
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10]
## [1,]    0    0    0    0    0    0    1    1    1    1
## [2,]    0    0    0    0    0    1    0    1    1    1
## [3,]    0    0    0    0    0    1    1    0    1    1
## [4,]    0    0    0    0    0    1    1    1    0    1
## [5,]    0    0    0    0    0    1    1    1    1    0
## [6,]    0    0    0    0    1    0    0    1    1    1
## [7,]    0    0    0    0    1    0    1    0    1    1
## [8,]    0    0    0    0    1    0    1    1    0    1
## [9,]    0    0    0    0    1    0    1    1    1    0
## [10,]   0    0    0    0    1    1    0    0    1    1
```

Par la suite, nous allons nous intéresser à un échantillon de taille $n = 100$ tiré dans une population de taille $N = 1270$. Le nombre total d'échantillon est C_N^n . La fonction `choose()` permet de calculer ce nombre:

```
n=100
N=nrow(popBZH)
choose(N,n)
```

```
## [1] 4.694853e+150
```

La fonction `srswor()` (Simple random sampling without replacement) renvoie un échantillon parmi les C_N^n possibles¹. Cette fonction prend comme argument d'entrée le couple (n, N) où n est le nombre d'individus à tirer parmi N individus et renvoie un vecteur de taille N avec un 1 au rang i si l'individu i a été sélectionné et 0 sinon. La fonction `getdata(data,s)` permet de récupérer le “sous-tableau” de `data` correspondant à l'échantillon `s` noté `data.sr`. Par exemple, si on tire un échantillon s de $n = 100$ communes dans le jeu de données, sans remise:

```
n<-100
Npop<-dim(popBZH)[1]
set.seed(3)
s.sr<-srswor(n=n,N=Npop)
index.sr <- which(s.sr==1)
data.sr <- getdata(popBZH,s.sr)
```

→ Quelle sont les communes que vous avez sélectionnées?

→ Représentez la variabilité de l'échantillon par rapport à la variabilité du jeu de données complet.

2.2 Estimation du total de la population en 2012

On considère un tirage *sans remise*, de $n = 100$ communes parmi les $N = 1\,270$ de la population. Le tableau de données correspondant à l'échantillon est stocké dans `data.s` (2.1).

L'estimateur sans biais du nombre total d'habitants est $T = N\bar{Y} = \frac{N}{n} \sum_{i=1}^n y_i$. On utilise la fonction `mean()` pour calculer l'estimation de la moyenne, puis pour calculer une estimation du total.

→ Expliquez ce que fait le code ci-dessous. Commentez les figures.

```
# Estimation du total
set.seed(10)
s <- srswor(n=100,N=Npop)
data.select <- getdata(popBZH,s)


tot.estim<-Npop*mean(data.select$pop_12)

tot.vrai = sum(popBZH$pop_12)
nb.simul<-1:10000
vec.tot.estim<-rep(NA,length(nb.simul))
for (i in nb.simul){
  s <- srswor(n=100,N=Npop)
  data.s <- getdata(popBZH,s)
  vec.tot.estim[i]<-Npop*mean(data.s$pop_12)
}
```


¹On note par ailleurs que la fonction `'sample()'` (fonction R de base) permet également de sélectionner n individus parmi N . Mais contrairement à `'srswor()'`, la fonction `'sample()'` renvoie le vecteur de taille n des *valeurs* des individus sélectionnés et non par un vecteur d'indices de ces individus dans la base.

```
hist(vec.tot.estim, col="lightblue", nclass=50)
abline(v=tot.vrai, col="red", lty=2, lwd=2)
```

Histogram of vec.tot.estim



```
tot.estim.cumul <- cumsum(vec.tot.estim)/nb.simul
plot(nb.simul,tot.estim.cumul,type="l")
abline(h=tot.vrai, lty=2, lwd=2,col="red")
```



L'estimateur sans biais de la variance de l'estimateur du nombre total d'habitants est: $\widehat{V(T)} = N^2 \frac{N-n}{N} \frac{S^2}{n}$. Dans l'échantillon tiré préalablement son estimation est:

```
s2 = var(data.select$pop_12) # fonction var de R : variance corrigée
varTot.estim <- Npop^2 * (Npop-n)/Npop * s2/n
varTot.estim
```

```
## [1] 88042990169
```

On en déduit un intervalle de confiance à 95% pour le total de la population en 2012. La fonction `qnorm()` permet d'obtenir la valeur du quantile de la loi Normale centrée-réduite:

```
alpha<-0.05
u <- qnorm(p=1-alpha/2, lower.tail = TRUE)
binf <- tot.estim - u * sqrt(varTot.estim )
bsup <- tot.estim + u * sqrt(varTot.estim )
binf
```

```
## [1] 2325977
```

```
bsup
```

```
## [1] 3489099
```

2.3 Estimation du nombre total de résidences secondaires en Bretagne en 2012

→ Reprendre la méthodologie précédemment introduite pour donner un intervalle de confiance à 95% pour le nombre de résidences secondaires en Bretagne, en 2012. NB: on se sert du même échantillon. . .

2.4 Sondage aléatoire simple avec remise

Pour aller plus loin, reprendre le même travail dans le cadre d'un sondage aléatoire simple avec remise.

3 Sondage aléatoire à probabilités inégales

Les plans simples équiprobables ne sont utilisés qu'en l'absence de toute autre information. Les sondages à probabilités inégales permettent d'utiliser une information auxiliaire (quantitative) dans le tirage des individus de l'échantillon.

Il existe alors un grand nombre de méthode de tirage aléatoire des individus. On présente ici un algorithme² simple dans son utilisation et sa mise en oeuvre: le sondage systématique à probabilités inégales. Le principe est le suivant:

²Madow, 1949

- On cumule pour tous les individus les probabilités d'inclusion:

$$\begin{aligned} V_1 &= \pi_1 \\ V_2 &= \pi_1 + \pi_2 \\ &\vdots \\ V_k &= \pi_1 + \pi_2 + \dots + \pi_k \\ &\vdots \\ V_N &= \pi_1 + \pi_2 + \dots + \pi_N \end{aligned}$$

- On génère une seule réalisation u de la loi $\mathcal{U}[0, 1[$
- On sélectionne l'individu i tel que $V_{i-1} < u < V_i$
- Puis j tel que $V_{j-1} < u + 1 < V_j$
- Puis k tel que $V_{k-1} < u + 2 < V_k$
- etc. on obtient in fine un échantillon de n individus

Cette procédure est implémentée dans le package R `sampling` dans la fonction `UPsystematic()`³.

On reprend ici l'exemple des données du recensement en Bretagne. On va améliorer l'estimation du total de la population de 2012 en se servant de l'information auxiliaire "nb-LogementsTotal".

Il faut d'abord calculer les probabilités d'inclusion de chaque individu de la population. La fonction `inclusionprobabilities()` prend en argument un vecteur a (variable auxiliaire) et un nombre n (taille d'échantillon):


```
X=popBZH$pop_09 # variable auxiliaire
X=popBZH$nb_LogementsTotal # variable auxiliaire

anova(lm(popBZH$pop_12~X))
```

```
## Analysis of Variance Table
##
## Response: popBZH$pop_12
##           Df      Sum Sq   Mean Sq F value    Pr(>F)
## X           1 8.1152e+10  8.1152e+10   68916 < 2.2e-16 ***
## Residuals 1268 1.4931e+09  1.1775e+06
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
plot(X,popBZH$pop_12)
```

³UP pour *Unequal Probability*: tous les algorithmes de tirage aléatoire avec probabilités inégales sont implémentés dans des fonctions dont le nom commence par UP dans le package 'sampling' de R



```
pik=inclusionprobabilities(X,n=100)
s=UPsystematic(pik) # choix d'un ?chantillon : m?thode syst?matique
data.select = getdata(popBZH,s) # ?chantillon observ?
```

On peut alors sélectionner un échantillon à partir de ces probabilités d'inclusion. Le tableau de données est stocké dans `data.select`.

Puis ensuite, on calcule l'estimateur de Horvitz-Thomson à partir de cet échantillon:

```
# HT estimateur
pik.select=pik[data.select$ID_unit]
tot.estimHT<- HTestimator(y=data.select$pop_12,pik=pik.select)
```

La fonction `varest()` permet de calculer l'estimation de la variance de l'estimateur de Horvitz-Thomson du total, d'après une méthode proposée par Deville⁴:

```
# variance estimation of the Horvitz-Thompson estimator
varTot.estimHT <- varest(Ys=data.select$pop_12,pik=pik.select)
```

On en déduit un intervalle de confiance au niveau 95%:

```
# IC 95%
alpha<-0.05
u <- qnorm(p=1-alpha/2, lower.tail = TRUE)
binfHT <- tot.estimHT - u * sqrt(varTot.estimHT )
bsupHT <- tot.estimHT + u * sqrt(varTot.estimHT )
binfHT
```

```
##           [,1]
## [1,] 3006016
```

⁴Deville, J.-C. (1993). Estimation de la variance pour les enquêtes en deux phases. Manuscript, INSEE, Paris

```
bsupHT
```

```
##           [,1]  
## [1,] 3287503
```

→ Comparer avec les résultats obtenus précédemment. Commenter.

4 Sondages et stratification

On s'intéresse maintenant au nombre de résidences secondaires.

Les communes sont ou non classées par la Loi littoral ⁵. On va utiliser cette information auxiliaire pour réaliser un sondage par stratification.

%Remarque: La démarche est décrite ici pour l'information auxiliaire "ClassementLoiLittoral", elle est similaire pour l'autre variable.

La variable `ClassementLoiLittoral` est une variable *qualitative*. On vérifie qu'elle est bien considérée comme telle par R (attention au codage 0/1 par exemple), et on la transforme au besoin en facteur:

```
popBZH$ClassementLoiLittoral<-as.factor( popBZH$ClassementLoiLittoral)
```

Les effectifs de chaque strates peuvent être obtenus grâce à la fonction `table()`:

```
tailles.strates <- table(popBZH$ClassementLoiLittoral)  
tailles.strates
```

```
##  
## non oui  
## 1001 269
```

On détermine le nombre d'individus à choisir dans chaque strates pour constituer l'échantillon par *allocation proportionnelle*:

```
# Effectifs d'échantillons par allocation proportionnelle:  
tailles.ech <- round(n * tailles.strates/Npop)  
tailles.ech
```

```
##  
## non oui  
## 79 21
```

```
sum(tailles.ech) # vérification: on a bien un échantillon de taille n
```

```
## [1] 100
```

On détermine le nombre d'individus à choisir dans chaque strates pour constituer l'échantillon par *allocation optimale (de Neyman)*:

⁵La Loi Littoral est une loi française qui vise à encadrer l'aménagement de la côte pour la protéger des excès de la spéculation immobilière et à permettre le libre accès au public sur les sentiers littoraux. La loi comporte un ensemble de mesures relatives à la protection et à l'aménagement du littoral et des plans d'eau intérieurs les plus importants.

```
# effectif d'échantillons par allocation de Neyman
Nh = tailles.strates
Sh = by(popBZH$nb_Residences2d,FUN=sd,INDICES=popBZH$ClassementLoiLittoral)
tailles.ech <- round(n*Nh*Sh/(sum(Nh*Sh)),0)
tailles.ech
```

```
##
## non oui
## 26 74
```

```
sum(tailles.ech)
```

```
## [1] 100
```

Dans le cas d'une stratification, l'estimateur du total est: $\hat{T}_{st} = \sum_{h=1}^H N_h \bar{Y}_h$, où H est le nombre de strates. En développant cette formule, on remarque que:

$$\hat{T}_{st} = \sum_{h=1}^H N_h \bar{Y}_h = \sum_{h=1}^H \left[\frac{N_h}{n_h} \sum_{i \in E_h} Y_i \right] = \sum_{h=1}^H \left[\frac{\sum_{i \in E_h} Y_i}{\frac{n_h}{N_h}} \right]$$

Or, $\frac{n_h}{N_h}$ est la probabilité d'inclusion d'ordre 1 d'un individu de la strate h dans l'échantillon. L'estimateur du total peut donc être vu comme la somme des estimateurs de Horvitz-Thomson calculés dans chaque strate, avec les probabilités d'inclusions égales au sein de chaque strate et valant $\frac{n_h}{N_h}$ (on a réalisé un tirage aléatoire simple, à probabilités égales, dans chacune des strates pour obtenir chaque sous-échantillon).

On peut calculer les probabilités d'inclusion ω_h pour les individus de la strate h :

```
wh <- tailles.ech / tailles.strates
wh
```

```
##
## non oui
## 0.02597403 0.27509294
```

Dans le package `sampling` de R, la fonction `strata(data, stratanames, size, method)` permet de tirer l'échantillon en tenant compte de la stratification. Elle prend en arguments: `data`: le tableau de données, `stratanames`: nom de la variable dans `data` qui code pour les strates, `size`: un vecteur de taille le nombre de strates qui indique le nombre d'individus à sélectionner par strate et `method`: la méthode de tirage au sein de chaque strate. La fonction `getdata()` permet ensuite de récupérer l'échantillon à partir du tableau de données.

```
s<-strata(data= popBZH, stratanames="ClassementLoiLittoral", size=tailles.ech,
method="srswor")
ech.strat<- getdata( popBZH, s)
```

Dans `ech.strat`, il existe des colonnes supplémentaires par rapport à `popBZH`:

```
names(ech.strat)
```

```
## [1] "Region_libelle" "DEPARTEMENT_libelle" "COG"
## [4] "COMMUNE_nom" "SURFACE_ha" "pop_09"
## [7] "pop_12" "nb_LogementVacants" "nb_LogementsTotal"
## [10] "nb_Residences2d" "ClassementLoiLittoral" "ID_unit"
## [13] "Prob" "Stratum"
```

On va s'intéresser en particulier à **Prob** et **Stratum** qui contiennent respectivement les probabilités d'inclusion et le numéro de la strate d'où est issu l'individu.

On se sert de ces informations pour calculer l'estimation du nombre total de résidences secondaires, à l'aide de la fonction `HTstrata(y,pik,strata,description)`. `y` est la variable d'intérêt, `pik` le vecteur des probabilités d'inclusion, de taille `n`, `strata` le vecteur indiquant la strate à laquelle appartient l'individu, de taille `n` et `description` est un argument optionnel pour afficher les totaux par strate.

```
tot.estimSt <- HTstrata(ech.strat$nb_Residences2d,ech.strat$Prob,ech.strat$Stratum,
                        description=TRUE)
```

```
## For stratum 1 ,the Horvitz-Thompson estimator is: 49588
## For stratum 2 ,the Horvitz-Thompson estimator is: 122409.5
## The Horvitz-Thompson estimator is:
```

```
tot.estimSt
```

```
##           [,1]
## [1,] 171997.5
```

On peut alors calculer la variance de l'estimateur du total et en déduire un intervalle de confiance:

```
varTot.estimSt <- varest(Ys=ech.strat$nb_Residences2d,pik=ech.strat$Prob)
varTot.estimSt
```

```
## [1] 238919955
```

```
alpha<-0.05
q <- qnorm(p=1-alpha/2, lower.tail = TRUE)
binfSt <- tot.estimSt - q * sqrt(varTot.estimSt)
bsupSt <- tot.estimSt + q * sqrt(varTot.estimSt)
binfSt
```

```
##           [,1]
## [1,] 141702.3
```

```
bsupSt
```

```
##           [,1]
## [1,] 202292.8
```

→ Quelle méthode d'allocation est à préconiser? Justifier.

→ Comparer avec les résultats obtenus précédemment. Commenter.

5 Simulations et propriétés asymptotiques des estimateurs

On peut vérifier simplement les propriétés des estimateurs utilisés, concernant leur biais par exemple. On considère par la suite le cas du **sondage aléatoire simple sans remise**. On procédera ensuite de même pour les autres estimateurs (Horvitz Thomson, stratification, etc.).

On constate que l'estimation du total observée sur l'échantillon est assez éloignée de la valeur réelle du nombre total d'habitants en 2012 (puisque nous avons cette information ici):

```
tot.vrai <- sum(popBZH$pop_12)
tot.vrai
```

```
## [1] 3199066
```

On va maintenant renouveler l'expérience du tirage un grand nombre de fois, par exemple 1000. Pour chacun des 1000 échantillons tirés, on calcule l'estimation du total. Ces valeurs obtenues sont stockées dans le vecteur `vec.tot.estim`.


On calcule ensuite, de façon séquentielle, à chaque nouvel échantillon tiré, la moyenne des estimateurs obtenu sur les échantillons déjà tirés. Il s'agit donc d'une moyenne "cumulée". On utilisera dans les calculs la fonction `cumsum()` de R, qui réalise directement la somme cumulée des éléments d'un vecteur:

```
cumsum(c(1,5,3))
```

```
## [1] 1 6 9
```

Ici, on va donc calculer le total estimé pour le premier échantillon. Puis, la moyenne des deux estimations du total pour les deux premiers échantillons. Ainsi de suite, on va procéder au calcul de la moyenne des estimations du total pour les *nb.simul* échantillons:

```
nb.simul <- 1:1000
vec.tot.estim <- rep(NA,length(nb.simul))
for (i in nb.simul){
  s <- srswor(n=10,N=nrow(popBZH))
  data.s <- getdata( popBZH,s)
  vec.tot.estim[i]<-N*mean(data.s$pop_12)
}
tot.estim.cumul <- cumsum(vec.tot.estim)/nb.simul
plot(nb.simul,tot.estim.cumul,type="l")
abline(h=tot.vrai, lty=2, lwd=2,col="red")
```



On constate sur la figure que la moyenne des estimations tend vers la vraie valeur du total. Ceci s'explique car l'estimateur $\hat{T}$ est un estimateur sans biais du total.

Là encore, l'estimation de la variance est très différente de la variance exacte, car elle dépend de l'échantillon tiré. Pour autant, l'estimateur est théoriquement sans biais.


```
vraiSigma2<- var( popBZH$pop_12)*(N-1)/N
# car fonction var() de R : variance corrig?e...
varTot.vrai <- N^2 * (N-n)/(N-1) *vraiSigma2/n
varTot.vrai
```

```
## [1] 967712571516
```

On peut le vérifier comme précédemment pour la moyenne: on calcule sur plusieurs échantillons la moyenne des estimations de la variance du total en fonction du nombre d'échantillons.

→ Que constate-t-on ?

```
nb.simul<-1:5000
vec.varTot.estim<-rep(NA,length(nb.simul))
for (i in nb.simul){
  s <- srswor(n=10,N=nrow(popBZH))
  data.s <- getdata( popBZH,s)
  s2 = var(data.s$pop_12)
  # fonction var() de R : variance corrig?e
  vec.varTot.estim[i]<-N^2 * (N-n)/N * s2/n
}
plot(nb.simul,cumsum(vec.varTot.estim)/nb.simul,type="l")
abline(h=varTot.vrai,col="red", lty=2, lwd=2)
```



→ Refaire le même travail pour les autres méthodes de sondage. Interpréter.

6 Pour aller plus loin: méthodes de redressement

On suppose maintenant que l'information auxiliaire utilisée ("nombre de logements" ou bien "Classement-Loi Littoral") n'est pas disponible pour l'ensemble de la population lors de la construction de l'échantillon.

6.1 Méthode du quotient (ou du ratio)

On a tiré un échantillon pour lequel on étudie une variable d'intérêt Y , mais on observe aussi une variable X , mesurant une information auxiliaire quantitative, dont on va se servir pour redresser l'estimateur du paramètre d'intérêt. Pour cette variable X , on connaît la moyenne μ_x de manière exacte sur la population. On peut "observer" le résultat $\bar{x}$ obtenu sur l'échantillon et le comparer à μ_x . L'idée est alors la suivante: pour une variable Y qui varie "proportionnellement" à la variable X , on tient compte du résultat $\bar{x}$ et on propose l'estimateur (de la moyenne de Y) redressé par le ratio :

$$\bar{Y}_R = \bar{Y} \times \frac{\mu_x}{\bar{X}} = R \times \mu_x$$

Si la valeur de $\bar{x}$ mesurée dans l'échantillon est inférieure à μ_x , il est intéressant de diminuer également l'estimation observée $\bar{y}$ (et inversement si $\bar{x} > \mu_x$). On rappelle ici que l'estimateur redressé par le ratio est biaisé, et que ce biais est de l'ordre de $1/n$. Il est donc d'autant plus faible que la taille d'échantillon est grande. Mais si la variable auxiliaire X et la variable Y étudiée sont *approximativement proportionnelles*, la variance de l'estimateur est inférieure à celle de l'estimateur usuel $\bar{Y}$; le biais étant d'un ordre de grandeur "dominé" par celui de l'écart-type, l'estimateur par le ratio est alors intéressant.

ePour estimer un total, on multiplie l'estimateur de la moyenne par la taille de la population N :

$$T_R = N \cdot \bar{Y}_R = N \times \bar{Y} \times \frac{\mu_x}{\bar{X}} = N \times R \times \mu_x$$

On réalise dans un premier temps un tirage aléatoire simple, sans remise, d'un échantillon de taille $n = 100$. Dans la suite, on va se servir de l'information auxiliaire qui concerne le nombre de logements. La fonction `ratioest()` permet d'obtenir l'estimateur redressé par la méthode du ratio. Elle prend en argument `y`: la variable d'intérêt (dans l'échantillon), `x`: la variable auxiliaire (dans l'échantillon), `Tx`: la somme des valeurs prises par la variable auxiliaire (dans la population), `pik`: le vecteur des probabilités d'inclusion pour les individus de l'échantillon:

```
wi <- rep(n/N,n)
# computes the ratio estimator
tot.estimR <- ratioest(y=data.sr$pop_12,x=data.sr$nb_LogementsTotal,
Tx=sum( popBZH$nb_LogementsTotal),pik=wi)
tot.estimR
```

```
## [1] 3209394
```

Dans le cas d'un sondage aléatoire simple, et si on a bien une relation de proportionnalité entre X et Y (estimateur sans biais), la variance de l'estimateur redressé par le ratio peut être estimée à partir de l'échantillon par:

$$V(\bar{Y}_R) = \frac{N-n}{Nn} [s_Y^2 + r^2 s_X^2 - 2r\hat{\rho}s_X s_Y]$$

où s_X^2 et s_Y^2 sont les variances corrigées de X et Y , estimées à partir de l'échantillon et $\hat{\rho}$ est le coefficient de corrélation linéaire entre X et Y , estimé sur l'échantillon. Pour la variance de l'estimateur du total, redressé par la méthode du quotient, on multiplie la variance de l'estimateur de la moyenne par N^2 . On en déduit l'intervalle de confiance:

```

sx2 <- var(data.sr$nb_LogementsTotal)
sy2 <- var(data.sr$pop_12)
# verif formule
r <- mean(data.sr$pop_12)/mean(data.sr$nb_LogementsTotal)
rho <- cor(data.sr$pop_12,data.sr$nb_LogementsTotal)
# variance
varTot.estimR <- N^2*(N-n)/(N*n)*(sy2 + r^2*sx2 -2*r*rho*sqrt(sx2)*sqrt(sy2))

# IC 95%
alpha<-0.05
q <- qnorm(p=1-alpha/2, lower.tail = TRUE)
binfR <- tot.estimR - q * sqrt(varTot.estimR)
bsupR <- tot.estimR + q * sqrt(varTot.estimR)

```

Remarque: on peut vérifier la relation de proportionnalité entre le nombre de logements et le nombre d'habitants en traçant le nuage de points et la droite des moindres carrés, déterminée à l'aide de la fonction `lm()`.

→ Comparez avec les résultats obtenus aux sections précédentes. Commentez.

6.2 Post-stratification

Dans ce cas, les strates sont connues *a posteriori*, c'est-à-dire après le tirage de l'échantillon. On réalise dans un premier temps un tirage aléatoire simple, sans remise, d'un échantillon de taille $n = 100$ (on pourrait envisager d'autres façon de constituer l'échantillon).

Au niveau de la population, on connaît néanmoins l'effectif total de chaque strate.

```

# tailles des strates dans la population
tailles.strates<- table(popBZH$ClassementLoiLittoral)

```

La fonction `poststrata()`, qui prend comme arguments le tableau de données correspondant à l'échantillon (`ech.SASSR`) et la variable qui définit les strates, retourne un objet `data.ps` qui contient d'une part un tableau de données (`data`), comportant le tableau de données correspondant à l'échantillon plus une colonne supplémentaire définissant à quelle strate appartient l'individu (`poststratum`) et d'autre part le nombre de post-strates (`npost`).

La fonction `postest()` permet de calculer l'estimateur du total redressé par post-stratification. Cette fonction prend en entrée un argument `data`: le tableau `data.ps$data` définit précédemment, `y`: la variable d'intérêt, `pik`: les probabilités d'inclusion de chaque individu de l'échantillon, `NG`: les effectifs de chaque strate, et `description`: argument optionnel pour afficher les totaux par post-strate. Ici, les probabilités d'inclusions sont égales à $\frac{n}{N}$ pour tous les individus (S.A.S. SR).

```

# découpage de l'échantillon en post-strates
data.ps=poststrata(data.sr,"ClassementLoiLittoral")
data.ps$npost # nb de post-strates

```

```
## [1] 2
```

```

# tailles des strates dans l'échantillon
tailles.ech<- table(data.sr$ClassementLoiLittoral)
tot.estimPS <- postest(data=data.ps$data,y=data.ps$data$nb_Residences2d,pik=rep(n/N,n),
                      NG=tailles.strates,description=TRUE)

```

```
## postratum 1
## the postratified estimator is: 59579.52
## postratum 2
## the postratified estimator is: 154750.3
```

```
tot.estimPS
```

```
## non
## 214329.8
```

On peut alors calculer la variance et en déduire un intervalle de confiance:

```
Wh = tailles.strates/N
Sh2 <- by(data.sr$nb_Residences2d, INDICES = data.ps$data$ClassementLoiLittoral, FUN=var) *
  tailles.strates/(tailles.strates-1)
varTot.estimPS <- N^2*(1/n-1/N)*sum(Wh*Sh2) +
  N^2*(1-n/N)/n^2 * sum(Sh2*(1-tailles.strates/N))
varTot.estimPS
```

```
## [1] 1692579192
```

```
alpha<-0.05
q <- qnorm(p=1-alpha/2, lower.tail = TRUE)
binfPS <- tot.estimPS - q * sqrt(varTot.estimPS )
bsupPS <- tot.estimPS + q * sqrt(varTot.estimPS )
binfPS
```

```
## non
## 133695
```

```
bsupPS
```

```
## non
## 294964.7
```

→ Comparer avec les résultats obtenus précédemment. Commenter.