

BUT2 Science des Données - IUT Vannes - 2025/2026
SAE 4.01 : prédire une variable quantitative
TP 1 et 2
G. Baron

Considérons une étude portant sur le poids de naissance des enfants. Des données ont été récoltées au Centre Médical de Baystate dans l'Etat du Massachussets aux Etats-Unis auprès de n=189 femmes. Il s'agit d'expliquer la variabilité du poids de naissance de l'enfant en fonction des caractéristiques de la mère, de ses antécédents et de son comportement pendant la grossesse. La variable dépendante est le poids de naissance de l'enfant (variable quantitative POIDS_NAISSANCE exprimée en grammes) et les facteurs étudiés (variables explicatives) sont regroupés en :

- Variables quantitatives continues : le poids de la mère au dernier cycle menstruel (variable POIDS en livres, 1 livre = 0.453 kg), l'âge de la mère (AGE en années).
- Variables quantitatives discrètes : nombre de visites chez le médecin pendant le premier trimestre de grossesse (RDV), le nombre d'antécédents de prématurité (TRAVAIL)
- Variables qualitatives : l'origine ethnique de la mère (ORIGINE : 1=blanche, 2=noire, 3=autre) ; le statut tabagique de la mère pendant la grossesse (FUMEUSE : 1=fumeuse, 0=non fumeuse), la présence d'antécédents d'hypertension (HTA : 1=Oui, 0=Non), la présence d'irritabilité utérine (IRRITABILITE : 1=Oui, 0=Non).

L'objectif final des séances de TD est de chercher à ajuster un modèle pour expliquer le poids de naissance en fonction des variables explicatives. On va s'intéresser tout d'abord au modèle de régression linéaire simple, avant d'explorer des modèles multivariés. Pour cette première séance, on considérera uniquement les variables explicatives quantitatives.

Bibliothèques de fonctions utiles

```
library(skimr) # stat desc
library(forcats) # pour les facteurs
library(naniar) # pour les valeurs manquantes
library(olsrr) # outils pour les modèles linéaires

library(tidyverse) # pour la gestion des données, dont dplyr et ggplot2
library(GGally) # extensions de ggplot2
library(ggpubr) # extensions de ggplot2 pour la personnalisation des graphiques
library(car) # fonction pour la regression
library(finalfit) # fonction pour la regression
library(performance) # pour l'évaluation de la performance d'un modèle de régression
```

Partie 1 : Import et préparation des données

- 1) Importer les données (fichier `dat_poidsnaïs.txt`) : vérifier la structure et les dimensions des données, puis adapter, si besoin, le mode de chaque colonne du tableau à la nature statistique des variables. Etudier la présence de valeurs manquantes (`miss_var_summary` et `gg_miss_var`).
- 2) Les variables TRAVAIL et RDV sont quantitatives discrètes, mais certaines valeurs sont nulles. Créer 2 nouvelles variables recodant ces 2 variables en variables binaires (0 : aucun / 1 : au moins 1). Utiliser la fonction `cut`.
- 3) Les variables qualitatives sont codées avec des modalités sous forme de nombre. Pour l'affichage dans les tableaux et graphiques, il est nécessaire d'avoir les variables codées avec les modalités en clair. Créer de nouvelles variables recodant ORIGINE, FUMEUSE, IRRITABILITE et HTA. Utiliser la fonction `fct_recode`.
- 4) Le poids du bébé et celui de la mère ne sont pas dans la même unité (livres vs kg). Calculer 1 nouvelle variable : `POIDS_kg` qui correspond au poids de la mère en kg (`transform`).
- 5) Vérifier la structure finale des données après ces étapes de préparation (`str + skim`).

Partie 2 : Etude du lien entre le poids de naissance du bébé (Y) et le poids de la mère (X)

- 1) Représenter graphiquement les 2 variables à l'aide d'un nuage de points (personnaliser le graphique : étiquettes des axes, couleurs et forme des points). Vérifier la linéarité.
- 2) Calculer et interpréter le coefficient de corrélation entre les 2 variables (`cor`, `cor.test`)

Partie 3 : Modèle de régression linéaire simple entre le poids de naissance du bébé (`POIDS_NAISSANCE`) et le poids de la mère (`POIDS_kg`)

- 1) Rappeler l'écriture du modèle de régression linéaire simple, en explicitant les notations utilisées.

Estimation des coefficients

- 2) Rappeler le nom de la méthode d'estimation, et son principe général. Quelles sont les hypothèses du modèle linéaire pour l'inférence ?
- 3) Pour estimer les paramètres, on utilise la fonction `lm`. Consulter également l'aide de la fonction (`?lm`). Utiliser cette fonction pour mettre en oeuvre une régression linéaire simple pour répondre à la problématique et donner les estimations des coefficients du modèle obtenus.
- 4) Après avoir identifié les estimations des paramètres, ajouter la droite de régression sur le nuage de points (`abline` ou `geom_smooth`).

Etude des résidus

- 5) Pourquoi l'analyse des résidus est-elle une étape primordiale pour l'étude d'un modèle ? Réaliser les diagnostics graphiques à partir des résidus studentisés (`rstudent`, diagnostics graphiques avec les fonctions du package `olsrr`).

Qualité du modèle et interprétation

- 6) Afficher le résumé du modèle (`summary`). Rappeler la définition, identifier dans la sortie R et interpréter les résultats du modèle :
 - Coefficients
 - Erreurs standards
 - Statistique T
 - Probabilités critiques
 - Coefficient de détermination (ajusté)
 - Statistique F

- Erreur résiduelle standard
- 7) Calculer les intervalles de confiance pour les coefficients du modèle ($\alpha=0.05$ ou 0.10) les résultats de l'estimation des coefficients

Prévision

- 8) Prévoir le poids de naissance d'un bébé pour une mère dont le poids est de 50, 60, ou 90 kg. (`predict`, avec `interval = "prediction"`). Pour prévoir la valeur de y pour une nouvelle observation x , on utilise les coefficients estimés. La valeur prédite seule a peu d'intérêt, étant donné l'erreur due à l'échantillonnage pour l'estimateur. On associe donc un intervalle de confiance à la prévision. On remarque que l'argument `newdata` de la fonction `predict()` est de type `data.frame`, et doit avoir le même nom de colonne pour la variable explicative (ici, `POIDS_kg`).

Partie 4 : Régression linéaire multiple avec variables explicatives quantitatives

Choix des données et étude exploratoire

- 1) Sélectionner un sous tableau des données comportant uniquement les variables quantitatives des données initiales (`POIDS_NAISSANCE`, `POIDS_kg`, `AGE`)
- 2) Etudier les corrélations 2 à 2 entre le poids de naissance, l'âge de la mère et le poids de la mère avec la fonction `ggpairs` du package `GGally`. La linéarité entre la variable à expliquer et les variables explicatives peut aussi être étudiée avec la fonction `scatterplotMatrix` du package `car`.

Modèle multivarié

- 3) Ecrire le modèle et ajuster le modèle linéaire avec 2 variables explicatives QT. Commenter les résultats :
 - Comparer les estimations obtenues avec celles du modèle 1 pour les coefficients β_0 et β_1 .
 - Comment interpréter le signe du coefficient β_1 du modèle 2 ?
 - Quelle est l'hypothèse du test sur le paramètre de régression β_1 ? Quelle est la valeur numérique du test ? Quelle est la distribution sous l'hypothèse nulle de la statistique de test ? Combien vaut le degré de signification ? Quelle conclusion en tirer ?
- 4) Faire une étude des hypothèses sous-jacentes du modèle (normalité des résidus, hypothèse d'homoscédasticité, sujets influents, etc), et comparer les performances avec le modèle 1.

Perspectives

- 5) Commenter la qualité du modèle, et proposer une amélioration.